TUTOR TOGAF

Informe de la segunda entrega

Asistente académico con recuperación aumentada por generación para consultar extractos autorizados de TOGAF 9.1.

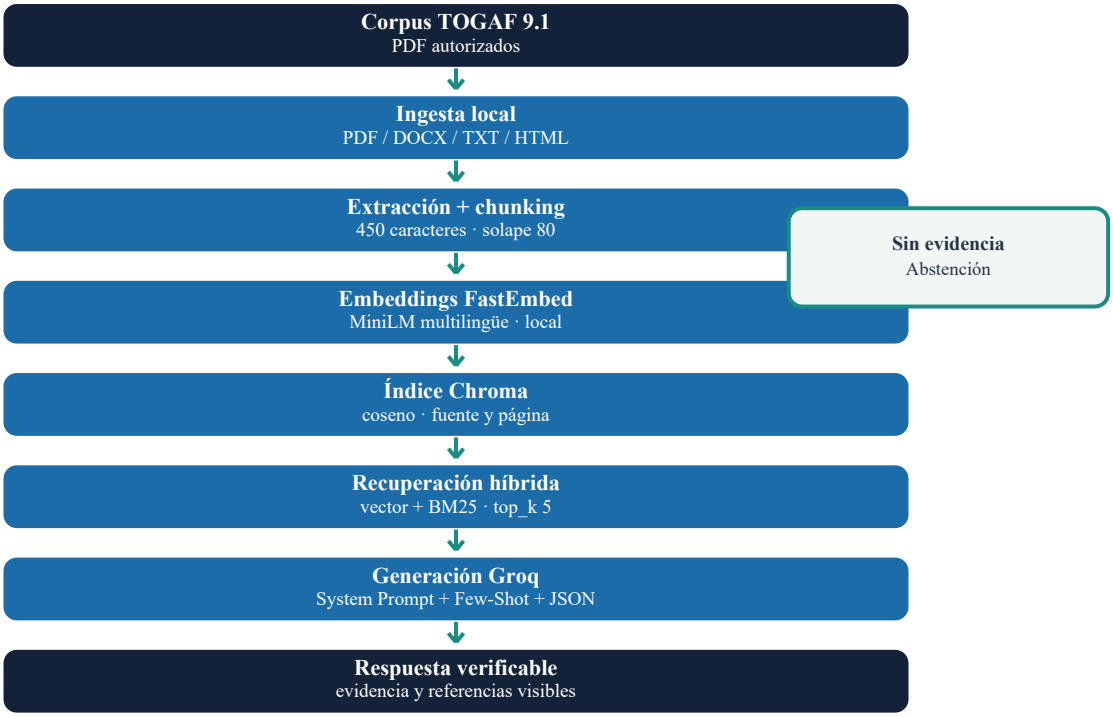
Corpus	6 extractos TOGAF 9.1
Evaluación	Ragas · 15 preguntas, 15 respondibles + 3 fuera del corpus
Aplicación pública	https://togaf-tutor-gvt5yxbedckatvnvha3xei.streamlit.app/
Repositorio	https://github.com/skallenfreck/TOGAF-Tutor

Síntesis

El sistema recibe documentos cargados por el usuario, extrae texto y metadatos, crea fragmentos con embeddings locales, recupera evidencia mediante búsqueda vectorial y léxica y genera respuestas con Groq. Cada respuesta expone documentos, páginas y fragmentos consultados; si falta evidencia, el flujo puede abstenerse.

Los PDF fuente están identificados como copias de evaluación y no se distribuyen dentro del repositorio. La aplicación pública solicita que cada usuario cargue documentos que tenga autorización para procesar.

Flujo RAG y decisiones



Etapa	Configuración	Justificación
Corpus e ingesta	6 extractos TOGAF 9.1; PDF, DOCX, TXT y HTML	Cubre ADM, fase preliminar, visión, negocio y vistas de datos y aplicaciones.
Chunking	450 caracteres; solapamiento 80; corte por párrafo/oración/palabra y por página	Mantiene contexto sin mezclar páginas y conserva la cita de origen.
Embeddings	FastEmbed · paraphrase-multilingual-MiniLM-L12-v2	Multilingüe, local y sin consumo de tokens de API para vectorizar.
Índice	Chroma, distancia coseno; metadatos de archivo y página	Permite persistencia local y trazabilidad visible de fuentes.
Recuperación	Vector + BM25; top_k base 3 frente a candidata 8; umbral 0.55	La búsqueda léxica ayuda con siglas; el experimento mide el efecto de ampliar candidatos.
Generación	Groq gpt-oss-20b; System Prompt, Few-Shot, delimitadores y JSON	Conserva el formato y reglas del Avance 1, limitando el contexto enviado al modelo a fragmentos recuperados.

La transcripción manual del diagrama ADM de la introducción se agrega durante la ingesta porque sus rótulos no se extraen como texto del PDF. Esto vuelve recuperables las fases y la gestión de requisitos.

Evaluación Ragas y comparación

Se evaluaron 18 preguntas: 15 con respuesta en el corpus y 3 de abstención. Para la iteración se cambió top_k de 3 a 8 y se mantuvieron los demás parámetros. Cada valor es el promedio sobre las mismas preguntas.

Métrica	Antes · top_k=3	Después · top_k=8	Cambio
Faithfulness	0.803	0.738	-0.066
Answer relevancy	0.729	0.696	-0.033
Context precision	0.561	0.469	-0.092
Context recall	0.533	0.733	+0.200

Interpretación

La métrica más baja en la configuración candidata fue **Context precision** (0.469). La menor context precision apunta a recuperación con fragmentos irrelevantes; conviene ajustar top_k, umbral o reranking para reducir ruido.

El cambio de top_k se considera una iteración experimental, no una mejora automática: la comparación debe leerse junto con las cuatro métricas y el control de abstención.

Control de abstención	top_k=3	top_k=8
Abstenciones correctas (de 3)	2	2
Omisiones (de 3)	1	1
Abstenciones falsas (de 15)	3	2
Fragmentos promedio recuperados	2.50	6.67

Nota metodológica: Answer relevancy solicitó tres generaciones, pero el proveedor devolvió una en algunas filas; Ragas continuó con esa generación. Esto puede aumentar la variabilidad de esa métrica y se reporta como limitación de la evaluación.

Análisis de consultas y control del alcance

Consulta sobre la fase A — Visión de Arquitectura

La respuesta capturada identifica los dos resultados centrales descritos por el extracto: una visión aspiracional de alto nivel y la aprobación del Statement of Architecture Work. La evidencia desplegada apunta a TOGAF_V9.1-VisionArquitectura.pdf, página 2, con similitud 0.823. La respuesta es directa y la cita permite comprobarla. Como mejora de presentación, conviene traducir los nombres de entregables sin borrar el nombre original en inglés.

Consulta sobre la secuencia del ADM

La captura muestra una respuesta que enumera las fases y relaciona el ciclo con actividades de arquitectura. La interfaz reporta evidencia de cinco fragmentos de cinco documentos, lo que aporta cobertura, aunque mezcla fuentes de varias secciones. El resultado Ragas concuerda con esa tensión: top_k=8 eleva context recall frente a top_k=3, pero reduce context precision; recuperar más contexto ayuda a cubrir la pregunta y aumenta la posibilidad de incluir pasajes secundarios.

Pruebas fuera del corpus

El conjunto incluye tres preguntas sin respuesta en los extractos: pasos detallados de la fase D, capital de Colombia y tamaño del equipo de arquitectura de una organización concreta. Con top_k=8, la evaluación registró 2 abstenciones correctas de 3; falló en una pregunta fuera del alcance. También registró 2 abstenciones falsas entre las 15 preguntas respondibles. Esto indica que el control de alcance funciona parcialmente y requiere seguir ajustando el umbral de evidencia y las instrucciones de abstención.

Seguimiento conversacional

La aplicación conserva el historial reciente para preguntas dependientes del turno anterior. La captura disponible solo documenta consultas individuales; no se adjuntó una captura verificable con dos turnos enlazados. También falta la captura de la interfaz mostrando una pregunta fuera del corpus y la abstención. La pestaña pública estaba sin documentos indexados durante la revisión, por lo que esas dos evidencias visuales deben tomarse desde una sesión con los PDFs cargados antes de presentar el PDF como evidencia completa de la interfaz conversacional.

Interfaz desplegada y evidencias

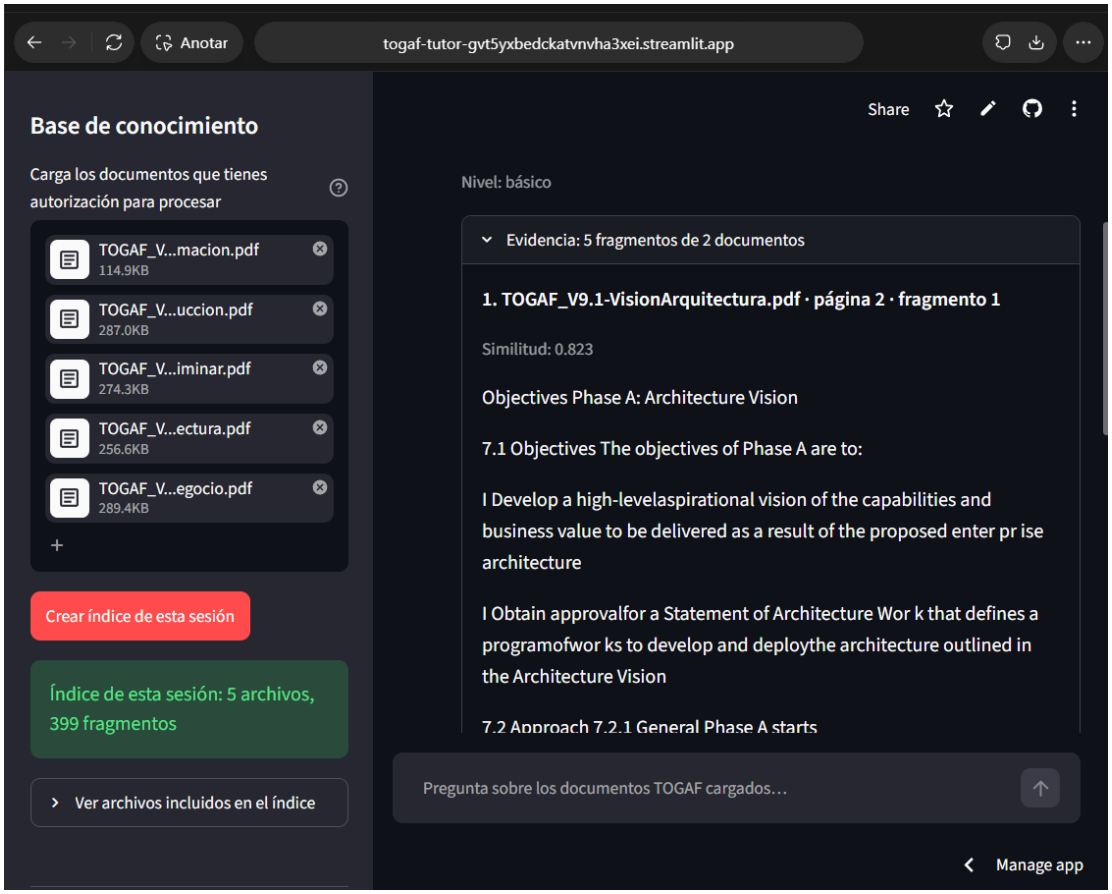
Aplicación pública: https://togaf-tutor-gvt5yxbedckatvnvha3xei.streamlit.app/
Repositorio: https://github.com/skallenfreck/TOGAF-Tutor

La interfaz permite cargar documentos, crear el índice de sesión, conservar el historial, consultar fragmentos y mostrar el documento, la página y la similitud de cada fuente.

Consulta sobre la fase A y respuesta generada en la app pública.



Evidencia recuperada: fragmento, documento, página y similitud.



Consulta sobre ADM y respuesta con varias fuentes.



Privacidad: la aplicación procesa los archivos cargados en la sesión; los embeddings se calculan localmente en el servidor. Para generar respuestas, envía a Groq la pregunta, el historial reciente y los fragmentos recuperados. No se deben publicar claves ni los PDF fuente.